

庆喜儿 AI 情感陪伴玩具

多方言自动识别、克隆音色合成与“阿西”唤醒词技术方案

文档版本：V1.1

文档类型：技术方案设计

编制日期：2026-07-17

项目仓库：shanjun-8399/qingxier

状态：V1.1 契约完成；真实实施测试待环境补齐

内部评审与实施基线

庆喜儿 AI 情感陪伴玩具

Table of Contents

庆喜儿 AI 情感陪伴玩具技术方案设计 V1.1

版本日期： 2026-07-17
变更范围： 多方言自动识别与克隆音色合成；唤醒词由“庆喜儿”改为“阿西”
适用范围： 设备固件、云端服务、微信小程序、运营后台、测试与验收
状态： 可开发/可联调方案；真实验收仍需服务器源码、小程序源码、固件、测试环境、第三方账号及设备

1. 变更摘要与决策

README 新需求包含两项：

- 1. 支持闽南语、吴语、粤语、四川话、陕西话、河南话、上海话等多种方言的识别与合成；设备自动检测，不要求用户手动切换；合成时保持同一克隆音色。
- 2. 唤醒词改为“阿西”。

本方案形成以下核心决策：

决策项	V1.1 方案	说明
实时 ASR	阿里云 DashScope fun-asr-realtime	官方能力覆盖普通话、粤语、吴语、闽南语及河南、陕西、四川等地区官话口音，适合作为主识别链路。
方言自动判定	新增 dialect-router，结合音频声学特征、ASR 文本特征和会话滞回	ASR 的自动语种识别不等于稳定输出细粒度方言标签，因此不能只依赖供应商语言字段。
克隆音色方言 TTS	cosyvoice-v3.5-flash 主路由；cosyvoice-v3-flash 兼容备选	两者支持声音复刻及方言指令控制，能够满足“统一克隆音色 + 方言输出”。
系统音色降级	qwen3-tts-flash-realtime	仅用于克隆音色不可用时的系统音色降级；该模型不支持声音克隆，不能作为主方案。
泛吴语处理	ASR 保留 wu；TTS 当前映射到 shanghai 并显式返回降级原因	供应商明确支持上海话克隆音色，但未承诺覆盖所有吴语次方言。正式验收应增加苏州/杭州等目标口音语料，并在供应商能力确认后取消降级。
唤醒词	ESP32-S3 本地 WakeNet9 定制模型，固定“阿西”	“阿西”只有两音节，低于常见 3-6 音节建议，需强化负样本、阈值、AFE/AEC/NS 和二次声学确认。
升级与回滚	唤醒词模型作为 wake_words OTA 包独立发布	支持灰度、哈希校验、失败回滚及版本可观测。

2. 需求口径与边界

2.1 目标方言枚举

V1.1 的业务枚举固定为：


mandarin	普通话
minnan	闽南语
wu	泛吴语（非上海细分类或未能细分的吴语）
cantonese	粤语
sichuan	四川话
shaanxi	陕西话
henan	河南话
shanghai	上海话
unknown	无法可靠判定（只用于内部中间态，不直接进入 TTS）

“吴语”和“上海话”同时存在是为了符合产品需求并保留可扩展性。上海话作为明确子类单独验收；其他吴语口音先归入 wu。不能把“供应商支持吴语识别”误写成“已支持所有吴语克隆合成”。

2.2 用户体验约束

- 默认和正常流程中不出现“请选择方言”步骤。
- 设备在每次语音会话开始后自动判断方言，并在会话内保持稳定，避免逐句跳变。
- 置信度低时自动使用本轮稳定方言或用户语音配置的兜底方言，不中断对话。
- 小程序可显示“当前识别为粤语/四川话”等状态，但该状态是可解释信息，不是强制手动选择器。
- 仅在诊断页或客服排障页提供受控的临时覆盖能力；生产普通用户页保持自动模式。
- 克隆音色不可用时必须明确记录降级到系统音色，不能静默伪装为克隆音色。

3. 总体架构调整



新增或调整的服务：

服务	V1.1 职责
speech-gateway	WSS 会话、音频流、VAD 事件、ASR/TTS 分片、超时和 Trace。
dialect-router	方言候选、置信度、会话滞回、用户兜底、路由决策及可解释原因。
tts-router	根据 voiceld、方言、供应商健康度和成本选择 CosyVoice/Qwen；产生降级信息。
voice-clone-service	授权、样本上传、训练回调、统一 voiceld、删除、审计和套餐额度。
speech-model-admin	ASR/TTS/唤醒模型版本、灰度比例、阈值、回滚、供应商开关。
device-service	增加语音配置、唤醒词状态、模型版本、阈值和 OTA 状态。

4. 多方言自动识别设计

4.1 处理流程

1. 设备本地识别“阿西”，启动录音并发送 start 帧。
2. 网关创建 speechSessionId，加载设备语音配置、用户上一轮稳定方言和当前模型配置。
3. ASR 调用 fun-asr-realtime。不设置 language_hints，由模型自动识别语种；中文会话继续进入细粒度方言判断。
4. dialect-router 对前 2-4 秒有效语音计算声学 embedding，并结合 ASR 文本中的词汇、语气词、音系特征和用户历史生成方言候选。
5. 使用置信度阈值与会话滞回确定稳定方言：
 - confidence >= 0.75：锁定候选方言；
 - 0.55 <= confidence < 0.75：优先沿用本轮已锁定方言；无已锁定值时采用用户历史稳定方言；
 - confidence < 0.55：采用设备 fallbackDialect，默认普通话；
 - 连续两轮高置信度与当前锁定值不一致时才允许切换。
6. 方言决策随 asr_result 帧返回，LLM 和 TTS 共享同一决策，避免“识别为一种方言、合成为另一种方言”。
7. 会话结束后只保存必要的统计、方言结果和脱敏文本；原始音频按用户授权及保存周期处理。

4.2 方言分类器实现建议

MVP 采用“供应商 ASR + 自有轻量分类器”而非重新训练完整 ASR：

- 输入：16kHz/16bit/mono 音频片段、ASR 文本、ASR 置信度、设备区域（可选且需授权）、历史稳定方言。
- 模型：ECAPA-TDNN/Whisper embedding 等声学特征 + 轻量文本分类器，最终用加权融合或小型分类头输出。
- 训练集：每类至少覆盖男女、儿童/成人、不同语速、1m/3m、安静/电视/音乐背景；禁止只使用单一城市单一说话人。
- 上海话与泛吴语必须分层标注，避免训练标签互相污染。

- 线上只保留 dialect, confidence, modelVersion, decisionSource；调试音频必须经过授权并设置 TTL。

4.3 自动识别失败策略

场景	处理
ASR 供应商超时	500ms 内切备用 ASR 或返回离线/网络兜底话术；不阻塞设备状态机。
方言分类置信度低	沿用会话方言；无会话方言时采用配置兜底。
混合普通话与方言	会话级保持主方言；仅在连续两轮出现高置信度变化时切换。
供应商不支持目标方言 TTS	返回 degraded=true、fallbackReason 和实际 providerDialect。
克隆音色训练失败或已删除	使用同人格系统音色；小程序显示“已临时使用默认音色”。

5. 方言克隆音色合成设计

5.1 模型路由

```
voiceId 存在且状态 succeeded
├── CosyVoice v3.5 Flash
│   ├── 目标方言在供应商指令支持表中 -> 克隆音色 + 方言指令
│   └── 泛吴语 wu -> providerDialect=上海话, degraded=true
voiceId 不存在 / 已删除 / 供应商克隆服务不可用
├── Qwen3-TTS Flash Realtime 系统音色降级
└── response.voiceMode=system_voice, 必须写入 fallbackReason
```

严禁出现以下错误组合：

```
model = qwen3-tts-flash* AND voiceId != null
```

服务端应返回 409101 VOICE_CLONE_UNSUPPORTED_BY_MODEL，避免调用后才发现能力不匹配。

5.2 音色统一与数据模型

一个用户/人格只绑定一个平台无关的业务 voiceId；供应商任务 ID、模型版本和样本 URL 是内部实现字段。建议数据结构：

```
{
  "voiceId": "voice_clone_mom_001",
  "userId": "u_001",
  "persona": "mom",
  "provider": "aliyun-dashscope",
  "providerVoiceId": "provider_voice_xxx",
  "modelFamily": "cosyvoice-v3.5",
  "status": "succeeded",
  "supportedDialects": ["minnan", "cantonese", "sichuan", "shaanxi", "henan", "shanghai"],
  "consentRecordId": "consent_001",
  "sampleDeletedAt": null,
  "createdAt": "2026-07-17T00:00:00Z"
}
```

不同方言合成仍使用同一个 providerVoiceId，通过方言指令控制发音风格。需要对同一批文本在不同方言下做说话人相似度与自然度双重验收。

5.3 合成缓存与延迟

- 常见问候、联网成功、低电量、提醒等固定文本按 voiceId + dialect + textHash + modelVersion 缓存。
- 对话链路采用 WebSocket 流式合成，首句先播，长回复分句生成。
- 缓存文件设置生命周期；克隆音色删除后必须清理相关缓存。
- 建议链路预算：
 - 终止点/VAD：200ms；
 - ASR 最终结果：350ms；
 - 方言路由：≤100ms；
 - LLM 首句：≤400ms；
 - TTS 首音频：≤450ms；
 - 端到端首音频 P95：≤1.5s（保留原验收目标）。

6. “阿西” 唤醒词设计

6.1 固件方案

- 芯片：ESP32-S3-WROOM-1。
- 引擎：ESP-SR WakeNet9 定制模型。
- 输入：16kHz、16-bit signed、mono PCM。
- 前端：AFE + AEC + NS + VAD；播放 TTS 时使用回声参考信号，避免自唤醒。
- 固定唤醒词：阿西；旧词“庆喜儿”从生产模型和产品文案中移除。
- 唤醒后设备上报 wakeWord, score, modelVersion, noiseLevel, playbackActive。

6.2 两音节风险控制

“阿西”仅两音节，短词更容易与自然对话、电视音频和近音词混淆。采取以下措施：

1. 采集不少于 2 万条合格正样本作为正式定制训练目标，覆盖 500 名以上说话人更佳，并包含儿童样本。

2. 构建至少 5 倍于正样本的 hard-negative 集：阿姨、阿喜、阿七、阿星、可惜、东西、电视对白、音乐歌词及设备自身 TTS。
3. 按 0.5m/1.5m/3m、快/中/慢语速、30/50/65dBA 噪声分桶调阈值。
4. 第一阶段 WakeNet 命中后，增加 150-250ms 轻量声学/音素复核；复核失败不进入云端录音。
5. 播放态提高阈值并启用 AEC，防止设备说出近音内容后自唤醒。
6. 阈值和模型版本支持远程灰度，不把阈值硬编码在固件业务逻辑中。

6.3 OTA 与回滚

唤醒词包结构：

```
{
  "packageType": "wake_words",
  "wakeWord": "阿西",
  "modelFamily": "WakeNet9",
  "version": "1.0.1",
  "hardwareRevisions": ["A1", "A2"],
  "sha256": "...",
  "threshold": 0.72,
  "rollout": {"percent": 10, "batches": ["pilot"]},
  "rollbackVersion": "1.0.0"
}
```

设备下载后先校验哈希与硬件版本，在备用资源分区加载自检；连续启动失败或唤醒模型加载失败时自动回滚，并上报 rolled_back。

7. 服务器设计调整

7.1 新增配置

```
ASR_PROVIDER=aliyun-dashscope
ASR_MODEL=fun-asr-realtime
DIALECT_ROUTER_MODEL=qingxier-dialect-router-v1
DIALECT_HIGH_THRESHOLD=0.75
DIALECT_MEDIUM_THRESHOLD=0.55
TTS_CLONE_MODEL=cosyvoice-v3.5-flash
TTS_SYSTEM_FALLBACK_MODEL=qwen3-tts-flash-realtime
WAKE_WORD=阿西
WAKE_WORD_MODEL_FAMILY=WakeNet9
WAKE_WORD_MIN_VERSION=wakenet9-axi-1.0.0
SPEECH_PROVIDER_TIMEOUT_MS=1500
SPEECH_PROVIDER_CIRCUIT_BREAKER=true
```

生产密钥仍应进入 KMS/CI Secret，不得写入仓库或小程序。

7.2 数据库调整

集合	关键字段	用途
speech_profiles	userId/deviceId, autoDialect, fallbackDialect, cloneVoiceId, thresholds	用户/设备语音偏好与兜底。

集合	关键字段	用途
speech_sessions	sessionId, dialect, confidence, source, modelVersion, latency	会话级方言锁定与观测。
speech_model_configs	provider, model, capability, status, rollout, cost	ASR/TTS 模型路由及灰度。
wake_word_packages	version, wakeWord, modelFamily, sha256, threshold, hardwareMatrix	唤醒词模型 OTA。
wake_word_events	deviceId, score, noise, modelVersion, accepted, falseWakeFeedback	唤醒效果分析。
conversation_turns 增量字段	language, dialect, dialectConfidence, asrModel, ttsModel, voiceld, fallbackReason	全链路可解释性。

索引建议：

- speech_profiles(deviceId) 唯一；
- speech_sessions(deviceId, createdAt desc)；
- wake_word_events(modelVersion, createdAt)；
- wake_word_packages(version, hardwareRevision) 唯一；
- 调试事件按 7-30 天 TTL，业务统计按脱敏策略保留。

7.3 安全与合规

- 声音克隆必须记录本人或监护人授权、用途、有效期和删除入口。
- 未成年人声音样本默认不用于模型再训练；供应商数据使用条款需法务确认。
- 方言识别不得隐式推断籍贯并用于营销画像；区域信息只作为可选技术特征且需授权。
- 声音样本、TTS 音频和原始对话音频使用独立桶、短期签名 URL、服务端加密和审计日志。
- 删除克隆音色时同步删除供应商音色、样本、缓存和人格绑定。

8. 小程序设计调整

8.1 页面变化

页面	V1.1 变化
设备控制台	显示“自动识别方言：已开启”、最近识别方言、唤醒词“阿西”和模型状态；不显示手动切换器。
人格与音色	展示克隆音色状态、支持方言、试听入口、当前降级状态和删除入口。
语音诊断	仅开发/客服角色可见：方言置信度、路由来源、ASR/TTS 模型、Trace ID。
OTA	增加“唤醒词模型”资源类型、版本、下载/安装/回滚状态。
隐私授权	增加声音克隆授权、样本删除和方言识别用途说明。

8.2 前端状态约束

- manualDialectSelectorVisible 必须为 false（普通用户态）。

- 用户可配置的是“低置信度兜底方言”，不是每次对话的手动方言。
- 服务端返回 degraded=true 时展示轻量提示，并允许上报问题，不阻断播放。
- 401001 跳转登录；409101 提示当前模型不支持克隆；503001 提示语音服务繁忙并使用默认音色。
- 前端只保存业务 Token，严禁保存设备密钥、第三方 API Key 或供应商 providerVoiceld。

9. 接口、WSS 与 MQTT 变更概览

详细定义见《欢喜儿 AI 玩具_接口变更说明_V1.1》；主要新增：

- GET /api/v1/speech/capabilities
- GET/PATCH /api/v1/devices/{deviceId}/speech-profile
- POST /api/v1/speech/sessions
- POST /api/v1/speech/route（内部/测试接口，生产可由 WSS 网关内聚）
- POST /api/v1/speech/tts（内部/调试）
- GET /api/v1/devices/{deviceId}/wake-word/status
- POST /api/v1/admin/wake-word-packages
- WSS start/asr_result/tts_start/tts_chunk/error 增加方言和模型字段。
- MQTT wake 事件增加模型版本、分数和噪声；OTA 包支持 wake_words。

10. 监控、告警与 SLO

指标	建议验收/告警口径
唤醒成功率	保留原标准：1.5m，幼儿版 $\geq 90\%$ ，成人版 $\geq 95\%$ ；按模型版本、噪声、距离分桶。
误唤醒	电视/音乐背景 1 小时 ≤ 2 次；近音词专项误触发率建议 $\leq 3\%$ 。
方言分类	验收集 macro-F1 ≥ 0.85 ；各目标方言 recall ≥ 0.80 ；上海话/泛吴语单列混淆矩阵。
ASR 质量	安静场景字符错误率 CER $\leq 15\%$ ；65dBA 背景噪声 CER $\leq 25\%$ （各方言分别统计）。
TTS 方言自然度	5 分制 MOS ≥ 4.0 ；方言正确性专家评分 ≥ 4.0 。
克隆相似度	统一量表/模型相似度 ≥ 0.85 ，且各方言间差异不超过 0.08。
端到端延迟	从用户停说到首音频 P95 $\leq 1.5s$ ；超时率 $< 1\%$ 。
降级率	克隆到系统音色降级 $< 2\%$ ；泛吴语到上海话映射单独统计，不混入故障率。
稳定性	72 小时无崩溃、无持续内存增长；WSS 重连成功率 $\geq 99\%$ 。

所有指标必须带 traceId/deviceIdHash/modelVersion/dialect/provider 标签，便于定位供应商、模型或特定方言问题。

11. 新增验收用例

ID	测试项	方法	通过标准
DIA-01	七类目标方言自动识别	每类至少 100 条多人语料，设备不做手动选择	macro-F1 >=0.85，各类 recall >=0.80。
DIA-02	无手动切换流程	从唤醒到连续 10 轮对话	不出现选择方言提示，路由可稳定完成。
DIA-03	会话滞回	方言中夹杂一轮普通话/低置信度音频	不发生单轮抖动；沿用会话主方言。
DIA-04	低置信度兜底	噪声/短语音使置信度 <0.55	使用配置兜底并返回原因。
DIA-05	上海话与泛吴语	上海、苏州/杭州目标语料分别测试	上海话单独识别；泛吴语不错误标记为高置信度上海话。
TTS-DIA-01	七类方言合成	同一克隆音色朗读统一文本集	方言正确性与自然度达标。
TTS-DIA-02	音色一致性	同一 voiceld 跨方言对比	相似度 >=0.85，方言间差异 <=0.08。
TTS-DIA-03	模型能力冲突	Qwen3-TTS-Flash + voiceld	服务端拒绝并返回 409101。
TTS-DIA-04	泛吴语降级	请求 wu 克隆音色	返回实际 providerDialect 和 fallbackReason，不静默降级。
WAK-01	“阿西”唤醒成功率	1.5m 各喊 20 次	幼儿 >=18，成人 >=19。
WAK-02	近音/电视误唤醒	近音词集 + 电视/音乐 1 小时	误唤醒 <=2 次/小时，近音误触发率 <=3%。
WAK-03	播放态防自唤醒	设备播放含近音词 TTS	不自唤醒。
WAK-04	唤醒词 OTA 回滚	下发损坏或不兼容模型包	自动回滚且设备仍可使用上一模型。
WAK-05	模型版本观测	唤醒并检查云端事件	事件包含 score/modelVersion/noiseLevel。

以上阈值是项目验收建议值，不是第三方供应商 SLA；上线前应由产品、算法、硬件和甲方共同冻结。

12. 实施顺序

1. 冻结方言枚举、验收语料范围与上海话/泛吴语边界。
2. 开通 DashScope ASR、CosyVoice、Qwen3-TTS 账号与测试额度；完成数据合规审查。
3. 固件集成 AFE/AEC/NS、WakeNet9 “阿西”模型、事件上报和唤醒词 OTA。
4. 云端实现 speech-gateway、dialect-router、tts-router、配置与数据模型。
5. 小程序实现能力发现、自动识别状态、克隆音色、诊断和唤醒词 OTA 展示。
6. 建立多人多环境音频集，先离线基准，再设备真机测试。
7. 执行接口、WSS、MQTT、真实语音、BLE、OTA、72 小时长稳和灰度回滚测试。
8. 达到验收指标后逐步扩大设备比例；异常时按模型版本快速回滚。

13. 当前实施阻塞

截至 2026-07-17，仓库仅包含 README 和设计/验收 Word 文档，没有服务器源码、小程序源码、设备固件、Docker/部署脚本、测试域名、第三方密钥、微信小程序账号、测试设备和音频语料。因此本次能够真实完成的是：

- 文档评审与 V1.1 技术方案；
- 新接口契约参考实现；
- 服务器与小程序的契约/状态流自动化测试；
- 完整报告模板和逐项阻塞记录。

真实服务器、小程序真机及设备验收不得在上述条件补齐前标记为通过。

14. 参考资料

1. 仓库 README 与 docs/ 下 V1.0 技术方案、API、部署清单、产品功能清单、硬件说明、验收标准。
2. 阿里云 Model Studio 语音识别模型说明（2026-07-17 核验）：Fun-ASR-Realtime 支持多语种及中文方言/地区口音。
3. 阿里云 Model Studio Fun-ASR-Realtime SDK 说明（2026-07-17 核验）：未设置 language_hints 时自动识别语种。
4. 阿里云 Model Studio 语音合成模型说明（2026-07-17 核验）：CosyVoice v3.5/v3 Flash 支持声音复刻与方言指令；Qwen3-TTS-Flash 不支持声音复刻。
5. Espressif ESP-SR 唤醒词定制说明（2026-07-17 核验）：WakeNet 定制语料、3-6 音节常规建议、16kHz/16bit/mono 输入和硬件声学测试要求。